Inférence d'État de Règles (RSI) : Un Cadre Bayésien pour la Surveillance de la Conformité dans les Domaines Régis par des Règles

Application aux Systèmes Fiscaux d'Afrique Francophone

Abdou-Raouf Atarmla[1,2*]

[1]Institut National des Postes et Télécommunications (INPT), Rabat, Maroc

[2]Togo DataLab, Ministère de l'Économie Numérique, Lomé, Togo

Emails : achilleatarmla@gmail.com | abdou-raouf.atarmla@datalab.gouv.tg

atarmla.abdouraouf@ine.inpt.ac.ma

2026

Abstract

Les cadres d'apprentissage automatique existants pour la surveillance de la conformité—réseaux logiques de Markov, logique floue probabiliste, modèles supervisés—partagent un paradigme fondamental : ils traitent les données observées comme une vérité de terrain et tentent d'approximer les règles à partir de celles-ci. Cette hypothèse s'effondre dans les *domaines régis par des règles*, tels que la fiscalité ou la conformité réglementaire, où les règles autorités sont *connues a priori* et où le véritable défi consiste à inférer l'*état latent* d'activation des règles, de conformité et de dérive paramétrique à partir d'observations partielles et bruitées.

Nous proposons **l'Inférence d'État de Règles (RSI)**, un cadre bayésien qui inverse ce paradigme en codant les règles réglementaires comme des a priori structurés et en formulant la surveillance de la conformité comme une inférence postérieure sur un espace d'états latents $\mathbf{S} = \{(a_i,\, c_i,\, \delta_i)\}_{i=1}^{n}$, où a_i capture l'activation de la règle, c_i modélise le taux de conformité, et δ_i quantifie la dérive paramétrique. Nous prouvons trois garanties théoriques : **(T1)** RSI absorbe les changements réglementaires en temps $O(1)$ via une correction de ratio d'a priori, indépendamment de la taille du jeu de données ; **(T2)** le posterior est consistent au sens de Bernstein-von Mises, convergeant vers le vrai état des règles à mesure que les observations s'accumulent ; **(T3)** l'inférence variationnelle champ-moyen maximise monotonement la borne inférieure de l'évidence (ELBO).

Nous instancions RSI sur le système fiscal togolais et introduisons **RSI-Togo-Fiscal-Synthetic v1.0**, un jeu de données de référence de 2 000 entreprises synthétiques ancré dans les règles réelles de l'OTR (2022–2025). Sans aucune donnée d'entraînement étiquetée, RSI atteint F1 $=$ 0,519 et AUC $=$ 0,599, tout en absorbant les changements réglementaires en 0,2 ms contre 407 ms pour le ré-entraînement complet—une accélération de 2 000$\times$.

Mots-clés : inférence bayésienne, domaines régis par des règles, surveillance de la conformité, inférence variationnelle, raisonnement zéro-shot, conformité fiscale, Afrique

*Travail indépendant. Correspondance : achilleatarmla@gmail.com

1 Introduction

L'apprentissage automatique a réalisé des progrès remarquables en reconnaissance de formes, prévision et classification. Pourtant, dans une large classe de domaines à forts enjeux—administration fiscale, conformité médicale, réglementation juridique, audit financier—les praticiens se heurtent à une difficulté structurelle récurrente : *la connaissance est déjà structurée*. Les règles ne sont pas inconnues. Elles sont écrites dans la loi, codifiées dans la réglementation et appliquées par des institutions.

Dans ces **domaines régis par des règles**, le défi n'est pas d'apprendre les règles à partir des données. Le défi est d'inférer *si les entités les respectent*, sachant que les observations sont partielles, stratégiquement manipulées et fréquemment manquantes. Un inspecteur fiscal n'a pas besoin d'un réseau de neurones pour déterminer qu'une entreprise avec 80 millions de FCFA de chiffre d'affaires est assujettie à la TVA—la loi le stipule. Ce dont il a besoin, c'est d'une méthode rigoureuse pour évaluer, à partir d'un ensemble incomplet de déclarations et de signaux comportementaux, l'état réel de conformité de cette entreprise.

Limites des approches existantes. Les classificateurs supervisés (XGBoost, réseaux de neurones) nécessitent des exemples étiquetés de non-conformité, qui sont rares, juridiquement sensibles et souvent indisponibles en pratique. Les réseaux logiques de Markov (MLN) [Richardson et Domingos, 2006] et la logique floue probabiliste (PSL) [Bach et al., 2017] traitent les poids des règles comme des quantités à *apprendre* à partir des données, inversant la direction épistémique. Les méthodes neurosymboliques [Garcéz et Lamb, 2022] combinent perception neuronale et raisonnement symbolique, mais leur composante symbolique demeure une approximation apprise. Aucun de ces cadres ne fournit : (i) une évaluation de conformité zéro-shot à partir de règles autoritées, (ii) une adaptation $O(1)$ aux changements réglementaires, ni (iii) une quantification native de l'incertitude interprétable par des auditeurs non techniques.

Nos contributions. Nous proposons **RSI (Rule-State Inference)**, un cadre bayésien qui formalise le paradigme inverse. Nos contributions sont :

(1) **Le cadre RSI** : une formalisation rigoureuse de la surveillance de la conformité comme inférence postérieure bayésienne sur un espace d'états latents, avec les règles comme a priori structurés (Section 3).

(2) **Trois garanties théoriques** : adaptabilité $O(1)$ aux changements réglementaires (T1), consistance postérieure de Bernstein-von Mises (T2), et convergence monotone de l'ELBO (T3) (Section 4).

(3) **RSI-Togo-Fiscal-Synthetic v1.0** : un jeu de données de référence publiquement disponible, ancré dans la loi fiscale togolaise, avec un événement de changement réglementaire documenté (Section 5).

(4) **Validation empirique** à travers cinq expériences démontrant des performances zéro-shot, une accélération $2\,000\times$ de mise à jour, et une robustesse à 50% de données manquantes (Section 5).

Pourquoi l'Afrique francophone. Nous ancrons notre cadre dans le système fiscal togolais pour trois raisons qui généralisent largement. Premièrement, la fréquence des changements réglementaires est élevée (plusieurs amendements par année fiscale), rendant l'adaptabilité non pas un luxe mais une nécessité. Deuxièmement, la qualité des données est structurellement faible : les revenus déclarés sont systématiquement sous-déclarés (ratio moyen de 0,70 dans notre benchmark), et 18–20% des variables fiscales clés sont manquantes. Troisièmement, les solutions ML développées pour les contextes à revenus élevés supposent une richesse de données qui n'existe tout simplement pas dans ces environnements. RSI est conçu *à partir* de ces contraintes, non adapté *pour* elles.

2 Travaux connexes

Logique probabiliste. Les MLN [Richardson et Domingos, 2006] combinent la logique du premier ordre avec les champs aléatoires de Markov via des formules pondérées, avec des poids appris à partir des données. La PSL [Bach et al., 2017] utilise des valeurs de vérité continues et réalise une inférence MAP tractable via l'optimisation convexe. Les deux traitent les poids des règles comme des *sorties* de l'apprentissage. RSI traite les règles comme des *entrées* : leur statut épistémique est a priori, non approximé. Dans les MLN, une formule de poids zéro est effectivement absente ; dans RSI, une règle avec a priori $\pi_i = 0,99$ est quasi-certaine et prime sur les preuves observationnelles faibles.

IA neurosymbolique. Garcez et Lamb [2022] décrivent des architectures allant des modèles en pipeline aux systèmes entièrement différentiables (Neural Theorem Provers [Rocktäschel et Riedel, 2017], LTN [Badreddine et al., 2022]). La direction canonique est l'*apprentissage pour le raisonnement* : la structure symbolique guide l'apprentissage neuronal. RSI occupe la position orthogonale : *raisonnement depuis les règles*, où la couche symbolique est fixée et autoritée, non apprise.

Apprentissage interprétable de règles. Les Listes de Règles Bayésiennes [Letham et al., 2015] appliquent la sélection de modèles bayésienne à des ensembles de règles—encore une fois, les règles sont la sortie. Notre travail produit non pas des règles mais des *distributions postérieures sur les états de conformité*—une cible d'inférence qualitativement différente.

IA et conformité fiscale. Le ML a été appliqué à l'estimation de l'écart fiscal [Gomes et al., 2022], à la sélection d'audits et à la détection de fraudes TVA, universellement sous des paradigmes supervisés. Aucun travail antérieur ne formalise la surveillance de la conformité comme une inférence d'état bayésienne.

Données manquantes et apprentissage en faible ressource. Frénay et Verleysen [2014] recensent l'apprentissage en présence de bruit de label. RSI adresse un défi connexe mais distinct : l'absence *structurelle* de données dans des environnements à faible intégrité. Notre vraisemblance gère les valeurs manquantes nativement en assignant une probabilité unitaire, préservant l'a priori sans injection de biais.

3 Le Cadre RSI

3.1 Formulation du problème

Soit $\mathcal{R} = \{r_1, \ldots, r_n\}$ un ensemble de règles réglementaires connues. Chaque règle $r_i : \mathcal{X} \times \Theta_i \to \{0, 1\}$ fait correspondre les attributs d'une entité $x \in \mathcal{X}$ et les paramètres de la règle Θ_i à un jugement binaire d'applicabilité. Soit $\mathbf{D} = \{d_1, \ldots, d_m\}$ un ensemble d'observations bruitées du comportement des entités.

Définition 1 (Domaine régi par des règles)**.** *Un domaine* $(\mathcal{R}, \mathcal{X}, \mathbf{D})$ *est* régi par des règles *si : (i)* $\mathcal{R}$ *est autorité et connue a priori ; (ii)* $\mathbf{D}$ *est partiel, potentiellement manquant, et peut être stratégiquement distorcé ; (iii) la tâche d'inférence principale est d'évaluer la conformité des entités avec* $\mathcal{R}$*, non de l'apprendre.*

3.2 L'espace d'états latents

Définition 2 (État de règle)**.** *L'état latent de la règle* r_i *est :*

$$s_i = (a_i,\ c_i,\ \delta_i), \quad \mathbf{S} = (s_1, \ldots, s_n) \in \mathcal{S}$$

où $a_i \in \{0, 1\}$ *indique si* r_i *est en vigueur,* $c_i \in [0, 1]$ *est le taux de conformité, et* $\delta_i \in \mathbb{R}$ *capture la dérive paramétrique.*

Intuition fondamentale. Cet objet n'a pas d'équivalent dans les cadres ML existants. Les MLN ont des poids de règles ; RSI a des états de règles. La différence est épistémique : les poids sont inférés à partir des données (données → règle) ; les états sont inférés étant donné les règles (règles + données → état).

3.3 L'a priori $P(\mathbf{S})$: les règles comme a priori structurés

Sous la factorisation champ-moyen :

$$P(\mathbf{S}) = \prod_{i=1}^{n} P(a_i)\, P(c_i \mid a_i)\, P(\delta_i \mid a_i)$$

$$a_i \sim \text{Bernoulli}(\pi_i) \tag{1}$$

$$c_i \mid a_i{=}1 \sim \text{Beta}(\alpha_i, \beta_i) \tag{2}$$

$$\delta_i \mid a_i{=}1 \sim \mathcal{N}(0,\ \sigma_i^2) \tag{3}$$

Les hyperparams $(\pi_i, \alpha_i, \beta_i, \sigma_i)$ encodent la connaissance institutionnelle : taux de conformité historiques, a priori sur l'activation des règles, stabilité paramétrique attendue.

3.4 La vraisemblance $P(\mathbf{D} \mid \mathbf{S})$

Les observations sont conditionnellement indépendantes :

$$P(\mathbf{D} \mid \mathbf{S}) = \prod_{j=1}^{m} P(d_j \mid \mathbf{S})$$

Pour chaque observation d_j :

$$P(d_j \mid \mathbf{S}) = \sum_{i:\, r_i \text{ applicable}} \Big[a_i \cdot \mathcal{L}(d_j \mid r_i, c_i, \delta_i) + (1 - a_i) \cdot \varepsilon \Big]$$

Gestion des données manquantes : quand d_j est absent, $P(d_j \mid \mathbf{S}) \equiv 1$, préservant l'a priori.

Nous utilisons des fonctions de vraisemblance *segmentées* par régime fiscal : (i) **TPU** (secteur informel, CA $<$ 30M FCFA) : signaux : délai de paiement, compte bancaire, ratio de sous-déclaration ; (ii) **TVA** (CA $\geq$ seuil) : TVA déclarée vs théorique, modèle bruit log-gaussien ; (iii) **IS** (CA $\geq$ 100M FCFA) : IS déclaré vs IS théorique donné le bénéfice déclaré.

3.5 Inférence postérieure

$$\boxed{P(\mathbf{S} \mid \mathbf{D}) \;\propto\; P(\mathbf{D} \mid \mathbf{S}) \cdot P(\mathbf{S})}$$

Le posterior supporte trois requêtes interprétables :

- $P(a_i{=}1 \mid \mathbf{D})$: probabilité que r_i soit active
- $\mathbb{E}[c_i \mid \mathbf{D}] \pm \sqrt{\mathrm{Var}[c_i \mid \mathbf{D}]}$: conformité attendue avec incertitude
- $\mathbb{E}[\delta_i \mid \mathbf{D}]$: dérive paramétrique estimée

Toutes les quantités sont directement interprétables par des auditeurs non techniques, sans outil d'explication post-hoc.

3.6 Inférence variationnelle champ-moyen

L'inférence exacte est intractable pour n grand. Nous approximons le posterior en minimisant $\mathrm{KL}[Q_\phi(\mathbf{S}) \| P(\mathbf{S} \mid \mathbf{D})]$, équivalent à maximiser :

$$\mathrm{ELBO}(\phi) = \mathbb{E}_{Q_\phi}[\log P(\mathbf{D} \mid \mathbf{S})] - \mathrm{KL}[Q_\phi(\mathbf{S}) \| P(\mathbf{S})]$$

Toutes les mises à jour sont *analytiques* (familles conjuguées) : Beta-Binomiale pour c_i, Bernoulli pour a_i, Gaussienne pour δ_i.

Algorithm 1: RSI : Inférence d'État de Règles (VI champ-moyen)

Input: Observations $\mathbf{D}$, Règles $\mathcal{R}$, A priori $\{\pi_i, \alpha_i, \beta_i, \sigma_i\}$
Output: Posterior $\{P(a_i|\mathbf{D}),\ \mathbb{E}[c_i|\mathbf{D}],\ \mathbb{E}[\delta_i|\mathbf{D}]\}$

```
Initialiser Q_φ ← P(S);
|ELBO_t − ELBO_{t−1}| < ε règle r_i ∈ R Calculer les signaux de conformité depuis D;
Mettre à jour Q(a_i) ← Bernoulli(ρ_i);
Mettre à jour Q(c_i) ← Beta(α_i + n_ok, β_i + n_chec);
Mettre à jour Q(δ_i) ← N(μ_post, σ²_post);
Calculer ELBO_t;
le résumé postérieur
```

4 Garanties Théoriques

4.1 T1 : Adaptabilité réglementaire en $O(1)$

Définition 3 (Mise à jour réglementaire)**.** *Une mise à jour $\mathcal{U}_k$ remplace r_k par r'_k, différant uniquement par les paramètres $\Theta_k \to \Theta'_k$. Le coût $\mathcal{C}(\mathcal{U}_k)$ compte les opérations requises.*

Théorème 1 (Adaptabilité $O(1)$)**.** *Pour toute mise à jour $\mathcal{U}_k$, le coût RSI est $\mathcal{C}^{\text{RSI}}(\mathcal{U}_k) = O(1)$, indépendamment de $|\mathbf{D}|$ et de n.*

Proof. L'a priori RSI se factorise en $P(\mathbf{S}) = \prod_i P(s_i|\Theta_i)$. Après $\mathcal{U}_k$, le posterior mis à jour satisfait :

$$P'(\mathbf{S} \mid \mathbf{D}) \;\propto\; P(\mathbf{S} \mid \mathbf{D}) \cdot \underbrace{\frac{P(s'_k \mid \Theta'_k)}{P(s_k \mid \Theta_k)}}_{\text{scalaire, } O(1)}$$

Ce ratio de correction ne dépend que des paramètres de la règle k. Son calcul nécessite l'évaluation de deux distributions paramétriques, soit $O(1)$ opérations.
Stabilité numérique. Le ratio est appliqué sur la *forme fonctionnelle* (le noyau) du posterior, et non sur sa valeur absolue. La constante de normalisation est mise à jour analytiquement grâce aux familles conjuguées (Beta-Bernoulli, Gaussienne-Gaussienne), garantissant que le posterior reste une distribution proprement normalisée. Il n'y a aucun risque d'explosion de variance ni de divergence numérique. □

Corollaire 1.1. *Sur T mises à jour réglementaires : RSI : $O(T)$; ML supervisé (ré-entraînement complet) : $O(T \cdot |\mathbf{D}| \cdot E)$; PSL/MLN : $O(T \cdot |\mathbf{D}| \cdot n)$. RSI domine dans les environnements à forte fréquence réglementaire.*

4.2 T2 : Consistance de Bernstein-von Mises

Théorème 2 (Consistance BvM)**.** *Soit $\mathbf{S}^*$ le vrai état des règles. Sous les conditions (C1) identifiabilité, (C2) $P(\mathbf{S}^*) > 0$, (C3) log-vraisemblance deux fois différentiable, (C4) information de Fisher $\mathcal{I}(\mathbf{S}^*)$ finie définie positive :*

$$\sqrt{m}\big(\hat{\mathbf{S}}_m - \mathbf{S}^*\big) \;\xrightarrow{d}\; \mathcal{N}\big(0,\, \mathcal{I}(\mathbf{S}^*)^{-1}\big) \quad (m \to \infty)$$

Preuve (esquisse). (i) La log-vraisemblance normalisée converge p.s. par la LGN. (ii) Un développement de Taylor au second ordre autour de $\mathbf{S}^*$ donne une approximation gaussienne. (iii) Sous (C2) et (C4), l'a priori est dominé par la vraisemblance quand $m \to \infty$, ce qui donne la limite gaussienne [van der Vaart, 2000]. □

Corollaire 2.1 (Robustesse à l'a priori)**.** *Pour deux a priori RSI quelconques P_1, P_2 : $\mathrm{TV}(P_1(\mathbf{S}|\mathbf{D}_m),\, P_2(\mathbf{S}|\mathbf{D}_m)) \to 0$ quand $m \to \infty$. Deux experts avec des croyances initiales différentes convergent vers la même évaluation de conformité.*

4.3 T3 : Convergence monotone de l'ELBO

Théorème 3 (ELBO Monotone)**.** *Les mises à jour par ascension de coordonnées RSI produisent une séquence ELBO monotone non décroissante : $\mathrm{ELBO}_{t+1} \geq \mathrm{ELBO}_t$ pour tout $t \geq 0$.*

Proof. Chaque mise à jour minimise $\mathrm{KL}[Q_{\phi_i} \| P(s_i|\mathbf{D})]$ en maintenant les autres facteurs fixés. Puisque $\mathrm{ELBO} = -\mathrm{KL}[Q_\phi \| P(\mathbf{S}|\mathbf{D})] + \log P(\mathbf{D})$ et que $\log P(\mathbf{D})$ est constant, chaque mise à jour ne peut pas diminuer l'ELBO [Blei et al., 2017]. □

5 Évaluation Expérimentale

5.1 Le jeu de données RSI-Togo-Fiscal-Synthetic

Nous introduisons **RSI-Togo-Fiscal-Synthetic v1.0**, un benchmark de 2 000 entreprises synthétiques ancré dans les règles officielles de l'OTR [OTR, 2024], structuré en quatre couches :

Caractéristiques des entreprises Secteur, région, CA déclaré.

Vérité terrain latente (a_i, c_i, δ_i) par règle— l'état non observé que RSI doit inférer.

Observations bruitées Taxes déclarées, proxys comportementaux (bancarisation, facturation électronique, délais de paiement), avec ratio de sous-déclaration moyen de 0,70 et 18–20% de données manquantes.

Étiquettes binaires Labels de conformité dérivés pour l'évaluation des baselines.

Le dataset encode cinq règles fiscales et un **événement de changement réglementaire documenté** : le relèvement du seuil TVA de 60M à 100M FCFA (Loi n°2024-007 du 30 décembre 2024), permettant la validation empirique directe du Théorème 1.

Réalisme du dataset. La distribution des chiffres d'affaires suit une loi log-normale par segment (TPU, RSI, réel), dont l'agrégation approxime une *loi de puissance* (Power Law) — la signature universelle des distributions de revenus dans les économies réelles [Gabaix, 2009]. Les 2 000 entreprises synthétiques ne sont pas uniformes : elles reproduisent la structure de concentration typique d'un marché africain (60% d'informel, 25% de PME, 15% de grands contribuables), garantissant que les résultats ne sont pas des artefacts d'un dataset simpliste.

5.2 Baselines et protocole expérimental

SBR Système à Base de Règles déterministe. Aucune incertitude. Fragile aux données manquantes.

XGBoost [Chen et Guestrin, 2016] Entièrement supervisé (150 estimateurs, profondeur 4).

MLP Entièrement supervisé (64-32-16, ReLU, early stopping).

Distinction critique. RSI opère en mode *zéro-shot* : aucun exemple étiqueté de conformité n'est utilisé. XGBoost et MLP sont entraînés sous supervision complète.

5.3 Résultats

Table 1: Comparaison des performances. RSI n'utilise *aucune étiquette*. † : supervision complète requise. **Gras** : meilleure performance zéro-shot.

Modèle	F1	AUC	Rappel	Étiquettes ?	Coût MAJ
RSI (le nôtre)	**0,519**	**0,599**	**0,909**	**Non**	0,2 ms
SBR	0,182	—	0,214	Non	∼0 ms
XGBoost†	0,967	0,999	0,978	Oui	407 ms
MLP†	0,087	0,747	0,153	Oui	61 ms

EXP-1 : Performance globale. RSI atteint F1 = 0,519 et AUC = 0,599 sans aucune donnée d'entraînement étiquetée, surpassant largement le système à base de règles (F1 = 0,182). Le rappel élevé (0,909) est cohérent avec les besoins des systèmes de surveillance fiscale, où manquer un fraudeur (*faux négatif*) est généralement plus coûteux institutionnellement qu'une fausse alarme (*faux positif*). RSI s'adapte naturellement à cette asymétrie via le calibrage du seuil de décision τ, sans modifier l'algorithme d'inférence. XGBoost atteint un F1 quasi-parfait sous supervision complète, mais ne peut pas opérer dans le cadre zéro-étiquette.

Table 2: Temps de mise à jour et F1 post-MAJ (période 2025).

Modèle	Temps MAJ	F1 post-MAJ	Ré-entraînement ?
RSI (le nôtre)	**0,2 ms**	0,411	Non
XGBoost	407 ms	0,954	Oui
MLP	61 ms	0,000	Oui

EXP-2 : Adaptabilité $O(1)$ (Théorème 1). RSI se met à jour en 0,2 ms—une accélération de $\mathbf{2\ 000}\times$ par rapport à XGBoost. Sur T mises à jour annuelles (Togo : $T \approx 4$–6), les économies cumulatives croissent linéairement en T et exponentiellement avec la taille du dataset, confirmant le Corollaire 1.

EXP-3 : Consistance BvM (Théorème 2). L'incertitude postérieure RSI $\sigma[c_i|\mathbf{D}]$ décroît monotonement avec la taille d'échantillon N, conforme au Théorème 2. Pour $N < 25$, RSI atteint un rappel compétitif tandis que XGBoost ne peut pas fonctionner (exemples étiquetés insuffisants).

EXP-4 : Robustesse aux données manquantes. Sous 20% de données manquantes (typique pour l'Afrique francophone), le F1 de RSI se dégrade de seulement $-0,003$ ($< 1\%$), tandis que le SBR perd $> 22\%$ de F1. À 50% de données manquantes, RSI reste fonctionnel (F1 = 0,521) alors que les méthodes déterministes s'effondrent.

EXP-5 : Convergence ELBO (Théorème 3). La séquence ELBO est empiriquement monotone non décroissante et converge en 7 itérations, confirmant le Théorème 3.

5.4 Interprétabilité : un exemple concret

Pour une entreprise avec un CA déclaré de 72M FCFA et aucune TVA déclarée, RSI produit :

- $P(\text{TVA active} \mid D) = 0,91$ — la règle s'applique très probablement
- $\mathbb{E}[c_{\text{TVA}} \mid D] = 0,23 \pm 0,18$ — faible conformité, forte incertitude
- $\mathbb{E}[\delta_{\text{TVA}} \mid D] = +2,4$M FCFA — dérive positive du seuil

Un auditeur agit directement sur cet output. *Le posterior est l'explication*—aucun outil post-hoc (SHAP, LIME) n'est nécessaire.

6 Discussion

Généralisabilité. RSI est agnostique au domaine. Les extensions immédiates incluent la conformité aux protocoles médicaux, la lutte anti-blanchiment, la surveillance environnementale et le suivi des contrats juridiques. Tout domaine satisfaisant la Définition 1 est candidat.

Limites. La qualité de l'inférence dépend de la précision des hyperparams de l'a priori. Des a priori mal spécifiés biaisent les résultats, bien que T2 garantisse la récupération asymptotique. Les fonctions de vraisemblance segmentées nécessitent actuellement une expertise du domaine ; des travaux futurs exploreront l'inférence amortie pour l'apprentissage de la vraisemblance.

Relation avec le filtrage de Kalman. RSI partage des parallèles architecturaux avec le filtre de Kalman : l'a priori joue le rôle du modèle de processus, la vraisemblance est le modèle de mesure, et le posterior est l'estimation d'état. Cette connexion ouvre des voies pour RSI séquentiel, suivant l'évolution des états de règles dans le temps.

Passage à l'échelle. La VI champ-moyen s'échelonne linéairement en n. Pour les codes fiscaux complets (centaines de règles), des extensions en graphes de facteurs via la propagation de croyances gèrent les dépendances entre règles.

7 Conclusion

Nous avons introduit **RSI (Rule-State Inference)**, un cadre bayésien qui inverse formellement le paradigme dominant de la surveillance de la conformité. En traitant les règles réglementaires autoritées comme des a priori structurés et en formulant l'évaluation de conformité comme une inférence postérieure sur un espace d'états latents, RSI offre ce qu'aucun cadre existant ne fournit : surveillance de conformité zéro-shot, adaptabilité réglementaire $O(1)$, quantification native de l'incertitude, et pleine interprétabilité.

Trois théorèmes établissent les fondements de RSI : adaptabilité $O(1)$ (T1), consistance de Bernstein-von Mises (T2), et convergence monotone de l'ELBO (T3). Les expériences sur RSI-Togo-Fiscal-Synthetic v1.0—ancré dans la loi fiscale togolaise réelle—valident les trois empiriquement et démontrent une accélération de $2\,000\times$ par rapport aux méthodes basées sur le ré-entraînement.

RSI est conçu pour les réalités des environnements régis par des règles dans les pays du Sud : changements réglementaires fréquents, rareté structurelle des données, et exigences institutionnelles de décisions auditable et interprétables. Nous publions le cadre complet, le dataset et l'implémentation pour soutenir la recherche reproductible.

Travaux futurs : RSI séquentiel pour le suivi longitudinal de la conformité, extensions multi-pays pour la zone CEDEAO, et vraisemblances apprises par inférence variationnelle amortie.

Remerciements

L'auteur exprime sa profonde gratitude au **Togo DataLab** (Ministère de l'Économie Numérique et de la Transformation Digitale) ainsi qu'à l'**Office Togolais des Recettes (OTR)** pour leur accueil, l'accès aux problématiques métier et leur expertise inéstimable sur le cadre réglementaire fiscal togolais.

Ce travail a également bénéficié de l'environnement académique de l'**Institut National des Postes et Télécommunications (INPT)** de Rabat. L'auteur tient à remercier ses collaborateurs et mentors pour les discussions enrichissantes qui ont permis de consolider les bases théoriques de ce cadre.

Note : Les opinions exprimées dans ce document sont celles de l'auteur et ne reflètent pas nécessairement les positions officielles des institutions mentionnées.

Déclaration IA : L'auteur a utilisé des outils assistés par IA pour la rédaction du manuscrit et la mise en forme LaTeX. Toutes les contributions scientifiques, affirmations théoriques, conception expérimentale et conclusions relèvent de la seule responsabilité de l'auteur.

References

Bach, S., Broecheler, M., Huang, B., et Getoor, L. (2017). Hinge-loss Markov random fields and probabilistic soft logic. *Journal of Machine Learning Research*, 18(109):1–67.

Badreddine, S., d'Avila Garcez, A., Serafini, L., et Spranger, M. (2022). Logic tensor networks. *Artificial Intelligence*, 303:103649.

Blei, D. M., Kucukelbir, A., et McAuliffe, J. D. (2017). Variational inference: A review for statisticians. *Journal of the American Statistical Association*, 112(518):859–877.

Chen, T. et Guestrin, C. (2016). XGBoost : A scalable tree boosting system. In *Actes de KDD*, pp. 785–794.

Frénay, B. et Verleysen, M. (2014). Classification in the presence of label noise: a survey. *IEEE Transactions on Neural Networks and Learning Systems*, 25(5):845–869.

Garcéz, A. d'Avila et Lamb, L. C. (2022). Neurosymbolic AI: The third wave. *Artificial Intelligence Review*.

Gabaix, X. (2009). Power laws in economics and finance. *Annual Review of Economics*, 1(1):255–294.

Gomes, M., Batista, J., et Carvalho, J. (2022). Machine learning for tax gap estimation. *Expert Systems with Applications*, 198:116810.

Letham, B., Rudin, C., McCormick, T. H., et Madigan, D. (2015). Interpretable classifiers using rules and Bayesian analysis. *Annals of Applied Statistics*, 9(3):1350–1371.

Office Togolais des Recettes (2024). Loi n°2024-007 du 30 décembre 2024 portant loi de finances pour l'exercice 2025. Lomé, Togo.

Richardson, M. et Domingos, P. (2006). Markov logic networks. *Machine Learning*, 62(1–2):107–136.

Rocktäschel, T. et Riedel, S. (2017). End-to-end differentiable proving. In *NeurIPS*, pp. 3788–3800.

van der Vaart, A. W. (2000). *Asymptotic Statistics*. Cambridge University Press.